



II.3 Técnicas de limpieza de datos

Extracción de Conocimiento en Bases de Datos

Luis Eduardo Aguilar Sarabia

IDGS91N

Docente: Luis Enrique Mascote Cano

Introducción

El presente caso de estudio tiene como finalidad aplicar técnicas de procesamiento, limpieza y modelado de datos al conjunto “International Migration – March 2021”, el cual contiene información sobre el número de migrantes clasificados según país de ciudadanía, tipo de visa y país de última residencia permanente. El objetivo principal es transformar este conjunto en una base de datos estructurada, confiable y optimizada que pueda servir de soporte para análisis estadísticos o sistemas de inteligencia de negocios relacionados con los flujos migratorios internacionales.

Durante la primera etapa se desarrollaron procedimientos de limpieza y depuración de datos, necesarios para garantizar su calidad, homogeneidad y consistencia. Posteriormente, se definieron las tablas de hechos y dimensiones que permiten representar de manera lógica el fenómeno migratorio dentro de un esquema analítico. Finalmente, se construyó un modelo relacional normalizado hasta la Tercera Forma Normal (3FN), junto con su script SQL, que refleja las relaciones entre las entidades principales y mantiene la integridad referencial de los datos.

Proceso

Limpieza de datos

1) Cargar y explorar

```
Primeras filas:
  year_month month_of_release passenger_type direction citizenship \
0  2020-02      2021-03 Long-term migrant Arrivals non-NZ
1  2020-09      2021-03 Long-term migrant Arrivals non-NZ
2  2020-07      2021-03 Long-term migrant Arrivals non-NZ
3  2020-07      2021-03 Long-term migrant Arrivals non-NZ
4  2020-01      2021-03 Long-term migrant Arrivals NZ
5  2020-02      2021-03 Long-term migrant Arrivals NZ
6  2020-09      2021-03 Long-term migrant Arrivals NZ
7  2020-12      2021-03 Long-term migrant Arrivals NZ

  visa country_of_residence estimate standard_error \
0 Resident Andorra 1 0
1 Resident Andorra 1 0
2 Visitor Andorra 1 0
3 NZ and Australian citizens Andorra 1 0
4 NZ and Australian citizens Andorra 1 0
5 NZ and Australian citizens Andorra 3 0
6 NZ and Australian citizens Andorra 1 0
7 NZ and Australian citizens Andorra 0 0

  status
0 Provisional
1 Provisional
2 Provisional
3 Provisional
4 Provisional
5 Provisional
6 Provisional
7 Provisional
```

2) Resumen de calidad (nulos / tipos / únicos)

```
  column dtype null_count null_pct unique
  year_month object 0 0.0 243
  month_of_release object 0 0.0 7
  passenger_type object 0 0.0 1
  direction object 0 0.0 1
  citizenship object 0 0.0 3
  visa object 0 0.0 7
  country_of_residence object 0 0.0 246
  estimate int64 0 0.0 4045
  standard_error int64 0 0.0 173
  status object 0 0.0 2
```

3) Normalizar nombres de columnas a snake_case

```
['year_month', 'month_of_release', 'passenger_type', 'direction', 'citizenship', 'visa', 'country_of_residence', 'estimate', 'standard_error', 'status']
```

4) Limpiar texto: strip, quitar no imprimibles, y casing por heurística

Textos normalizados. Ejemplo:

	year_month	month_of_release	passenger_type	direction	citizenship	\
0	2020-02	2021-03	Long-term migrant	Arrivals	Non-Nz	
1	2020-09	2021-03	Long-term migrant	Arrivals	Non-Nz	
2	2020-07	2021-03	Long-term migrant	Arrivals	Non-Nz	
3	2020-07	2021-03	Long-term migrant	Arrivals	Non-Nz	
4	2020-01	2021-03	Long-term migrant	Arrivals	Nz	

	visa	country_of_residence	status
0	RESIDENT	Andorra	Provisional
1	RESIDENT	Andorra	Provisional
2	VISITOR	Andorra	Provisional
3	NZ AND AUSTRALIAN CITIZENS	Andorra	Provisional
4	NZ AND AUSTRALIAN CITIZENS	Andorra	Provisional

- 5) Detectar y convertir columnas numéricas almacenadas como texto

```
def looks_numeric(series, threshold=0.9):
    s = series.dropna().astype(str)
    if len(s)==0: return False
    numeric_like = s.str.replace(r'[,\\s]', '', regex=True).str.match(r'^-?\d+(\.\d+)?$')
    return numeric_like.mean() >= threshold

for c in df.columns:
    if df[c].dtype == 'object' and looks_numeric(df[c]):
        df[c] = df[c].astype(str).str.replace(',','').str.replace(' ','')
        df[c] = pd.to_numeric(df[c], errors='coerce')
```

- 6) Parsear year_month y crear time_key (si existe)

Time_key creado. Ejemplo:

	year_month	year_month_parsed	time_key
0	2020-02	2020-02-01	202002
1	2020-09	2020-09-01	202009
2	2020-07	2020-07-01	202007
3	2020-07	2020-07-01	202007
4	2020-01	2020-01-01	202001

- 7) Eliminar duplicados exactos

Duplicados exactos encontrados: 0

- 8) Elegir columnas clave para agrupar

`['year_month', 'month_of_release', 'passenger_type', 'direction', 'country_of_residence', 'status']`

- 9) Agregar (sumar estimate) y recomputar standard_error correctamente

```
Agrupado. Filas antes: 401772 -> filas después: 45621
  year_month month_of_release passenger_type direction \
0    2001-01         2020-09 Long-term migrant Arrivals
1    2001-01         2020-09 Long-term migrant Arrivals
2    2001-01         2020-09 Long-term migrant Arrivals
3    2001-01         2020-09 Long-term migrant Arrivals
4    2001-01         2020-09 Long-term migrant Arrivals
5    2001-01         2020-09 Long-term migrant Arrivals

  country_of_residence status estimate standard_error
0      Afghanistan Final         24          0.0
1 Africa And The Middle East Final      3012          0.0
2      Antarctica Final         12          0.0
3      Argentina Final         40          0.0
4        Asia Final      11860          0.0
5      Australia Final       5428          0.0
```

10) Detectar outliers en la medida (IQR) y marcar

```
Outliers IQR bounds: -226.0 398.0
Outliers encontrados: 7642
```

11) Eliminar filas con estimate negativo

```
Filas con estimate negativo: 0
```

12) Guardar CSV limpio

```
CSV limpio guardado en: staging_migration_clean_final_estimate.csv
```

Determinación de hechos y dimensiones

Tabla de Hechos (Fact Table)

- **FactMigration:** Esta tabla contendrá las métricas cuantitativas del proceso que se está midiendo: la migración.
 - **Propósito:** Almacenar los valores numéricos clave del conjunto de datos, como el número estimado de migrantes y su error estándar. Es el núcleo del modelo, desde donde se realizarán las principales consultas analíticas.
 - **Medidas:** estimate, standard_error.

Tablas de Dimensiones (Dimension Tables)

Estas tablas contendrán los atributos descriptivos que dan contexto a los datos de la tabla de hechos.

- **DimDate:**

- **Propósito:** Proporcionar el contexto temporal. Permitirá analizar las tendencias de migración a lo largo del tiempo (por año, mes, etc.).
- **Atributos:** DateKey, YearMonth, MonthOfRelease, Year, Month.
- **DimPassenger:**
 - **Propósito:** Describir el tipo de pasajero.
 - **Atributos:** PassengerKey, PassengerType.
- **DimGeography:**
 - **Propósito:** Almacenar la información geográfica, en este caso, el país de residencia.
 - **Atributos:** CountryKey, CountryOfResidence.
- **DimCitizenship:**
 - **Propósito:** Segmentar los datos por la ciudadanía del migrante.
 - **Atributos:** CitizenshipKey, Citizenship.
- **DimVisa:**
 - **Propósito:** Describir el tipo de visa utilizada por el migrante.
 - **Atributos:** VisaKey, Visa.
- **DimDirection:**
 - **Propósito:** Indicar la dirección del movimiento migratorio (llegadas o salidas).
 - **Atributos:** DirectionKey, Direction.
- **DimStatus:**
 - **Propósito:** Indicar si los datos son provisionales o finales.
 - **Atributos:** StatusKey, Status.

Normalización y almacenamiento

```
CREATE DATABASE MigrationData

USE MigrationData

-- Dimensión de Tiempo
CREATE TABLE DimDate (
    DateKey INT PRIMARY KEY,
    YearMonth VARCHAR(7) NOT NULL,
    MonthOfRelease VARCHAR(7) NOT NULL,
    Year INT,
    Month INT
);

-- Dimensión de Tipo de Pasajero
CREATE TABLE DimPassenger (
    PassengerKey INT PRIMARY KEY,
    PassengerType VARCHAR(50) UNIQUE NOT NULL
);

-- Dimensión Geográfica
CREATE TABLE DimGeography (
    CountryKey INT PRIMARY KEY,
    CountryOfResidence VARCHAR(100) UNIQUE NOT NULL
);

-- Dimensión de Ciudadanía
CREATE TABLE DimCitizenship (
    CitizenshipKey INT PRIMARY KEY,
    Citizenship VARCHAR(50) UNIQUE NOT NULL
);

-- Dimensión de Visa
CREATE TABLE DimVisa (
    VisaKey INT PRIMARY KEY,
    Visa VARCHAR(50) UNIQUE NOT NULL
);

-- Dimensión de Dirección
CREATE TABLE DimDirection (
    DirectionKey INT PRIMARY KEY,
    Direction VARCHAR(20) UNIQUE NOT NULL
);

-- Dimensión de Estado
CREATE TABLE DimStatus (
    StatusKey INT PRIMARY KEY,
    Status VARCHAR(20) UNIQUE NOT NULL
);

-- Tabla de Hechos de Migración
CREATE TABLE FactMigration (
    MigrationID INT PRIMARY KEY,
    DateKey INT,
    PassengerKey INT,
    CountryKey INT,
```

```

CitizenshipKey INT,
VisaKey INT,
DirectionKey INT,
StatusKey INT,
Estimate INT,
StandardError INT,
FOREIGN KEY (DateKey) REFERENCES DimDate(DateKey),
FOREIGN KEY (PassengerKey) REFERENCES DimPassenger(PassengerKey),
FOREIGN KEY (CountryKey) REFERENCES DimGeography(CountryKey),
FOREIGN KEY (CitizenshipKey) REFERENCES DimCitizenship(CitizenshipKey),
FOREIGN KEY (VisaKey) REFERENCES DimVisa(VisaKey),
FOREIGN KEY (DirectionKey) REFERENCES DimDirection(DirectionKey),
FOREIGN KEY (StatusKey) REFERENCES DimStatus(StatusKey)
);

```

Conclusión

La aplicación de un proceso estructurado de limpieza, transformación y modelado de datos permitió convertir el conjunto “*International Migration – March 2021*” en una base de datos confiable, coherente y analíticamente útil. A través de la limpieza sistemática en Python se corrigieron errores, se homogenizaron formatos y se revisaron registros duplicados, asegurando la calidad del dataset. La determinación de hechos y dimensiones permitió identificar los elementos esenciales para el análisis de los flujos migratorios, mientras que la normalización hasta 3FN garantizó la integridad y eficiencia del almacenamiento de la información.

El resultado final es una base de datos estructurada y lista para ser utilizada en contextos de análisis estadístico o inteligencia de negocios, ofreciendo una representación clara de los movimientos migratorios según ciudadanía, tipo de visa y país de residencia. Este caso evidencia la importancia de la preparación y modelado adecuado de los datos como base fundamental para la generación de conocimiento, la planificación estratégica y la toma de decisiones basadas en información confiable.